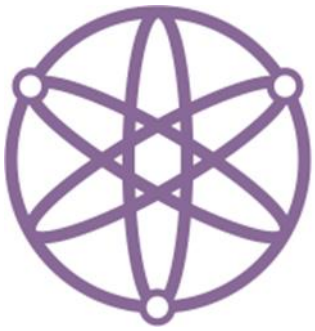

WYDZIAŁ
MATEMATYKI
I FIZYKI STOSOWANEJ
POLITECHNIKI RZESZOWSKIEJ

# Wnioskowanie w warunkach niepewności

Projekt

**Gabriel Lichacz**

Rzeszów, 2022

# Spis treści

# 1. Wstęp

Dane dotyczą zaburzeń wątroby i pochodzą z BUPA Medical Research Ltd. Pięć pierwszych zmiennych to badania krwi, które uważa się za wrażliwe na zaburzenia wątroby, wynikające z nadmiernego spożywania alkoholu. Każdy wiersz danych to pojedyncza osoba płci męskiej. Zbiór nie zawiera informacji o tym czy dana osoba posiada dolegliwości wątroby. Zestaw danych posiada 345 wierszy oraz sześć kolumn danych.

Zmienne w zbiorze:

[1] mcv – wskaźnik średniej objętości krwinki czerwonej
[2] alkphos – fosfataza alkaliczna
[3] sgpt – aminotransferaza alaninowa
[4] sgot – aminotransferaza asparaginianowa
[5] gammagt – gamma-glutamylotranspeptydaza
[6] drinks – ilość napojów alkoholowych objętości pół pinty wypijanych dziennie
[7] class – pole z selektorem stworzonym przez badaczy BUPA do podziału danych na zbiory testowe

# 2. Budowa sieci

## 2.1. Wstępna obróbka danych

Dane po wczytaniu konwertuję dla pewności na typ numeric oraz usuwam kolumnę class. Nie wnosi ona nic do badanych danych a może wpłynąć negatywnie na model sieci.

| | mcv | alkphos | sgpt | sgot | gammagt | drinks |
|---|---|---|---|---|---|---|
| 1 | 85 | 92 | 45 | 27 | 31 | 0.0 |
| 2 | 85 | 64 | 59 | 32 | 23 | 0.0 |
| 3 | 86 | 54 | 33 | 16 | 54 | 0.0 |
| 4 | 91 | 78 | 34 | 24 | 36 | 0.0 |
| 5 | 87 | 70 | 12 | 28 | 10 | 0.0 |
| 6 | 98 | 55 | 13 | 17 | 17 | 0.0 |
| 7 | 88 | 62 | 20 | 17 | 9 | 0.5 |
| 8 | 88 | 67 | 21 | 11 | 11 | 0.5 |
| 9 | 92 | 54 | 22 | 20 | 7 | 0.5 |
| 10 | 90 | 60 | 25 | 19 | 5 | 0.5 |

rys. 2-1 Dane

Przeprowadzam test Shapiro-Wilka na normalność rozkładu.

```
shapiro_t <- c()
for(i in 1:(length(dane)-1)){
  shapiro_t[i] <- shapiro.test(dane[,i])$p
}
shapiro_t
```

| **Kolumna** | mcv | alkphos | sgpt | sgot | gammagt | drinks |
|---|---|---|---|---|---|---|
| **Wartość p** | 3.340830e-06 | 3.604551e-07 | 2.579879e-23 | 1.402884e-19 | 6.480735e-25 | 1.686482e-18 |

tab. 1 Wartości p dla zmiennych

Obliczone wartości p są znacznie mniejsze niż α = 0,05, co oznacza, że żadna ze zmiennych nie ma charakteryzuje się rozkładem normalnym. Dane należy zdyskredytować.

## 2.2. Dane ciągłe

Modele zbudowane dla oryginalnych danych. Stworzone w celach poglądowych.

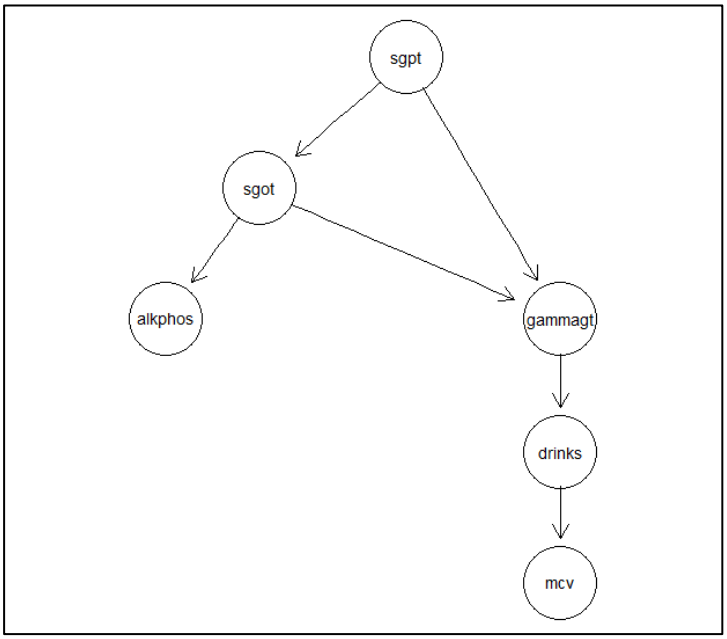


rys. 2-2 Sieć zbudowana algorytmem hc dla danych ciągłych

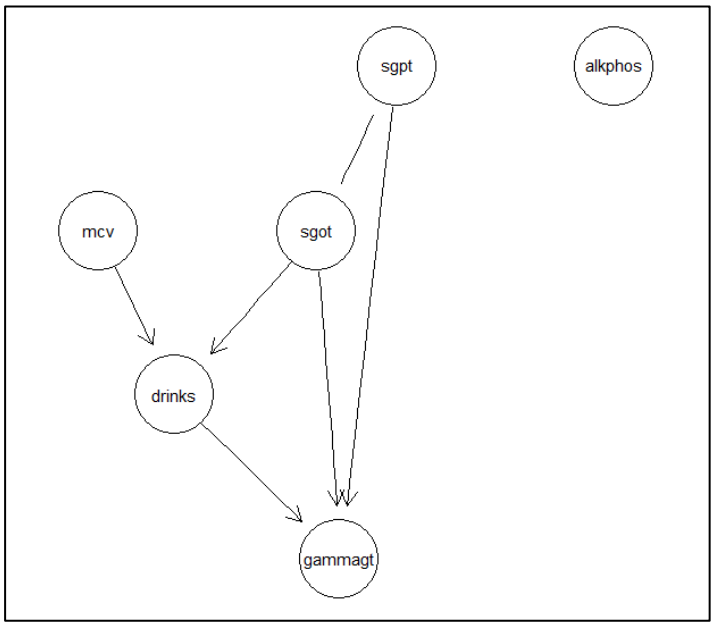


rys. 2-3 Sieć zbudowana algorytmem pc.stable dla danych ciągłych

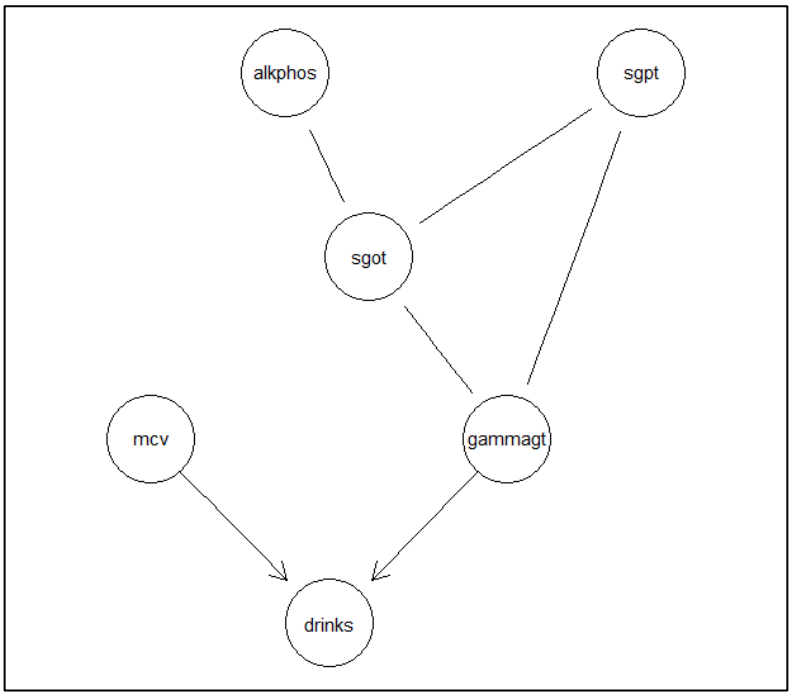

rys. 2-4 Sieć zbudowana algorytmem gs dla danych ciągłych

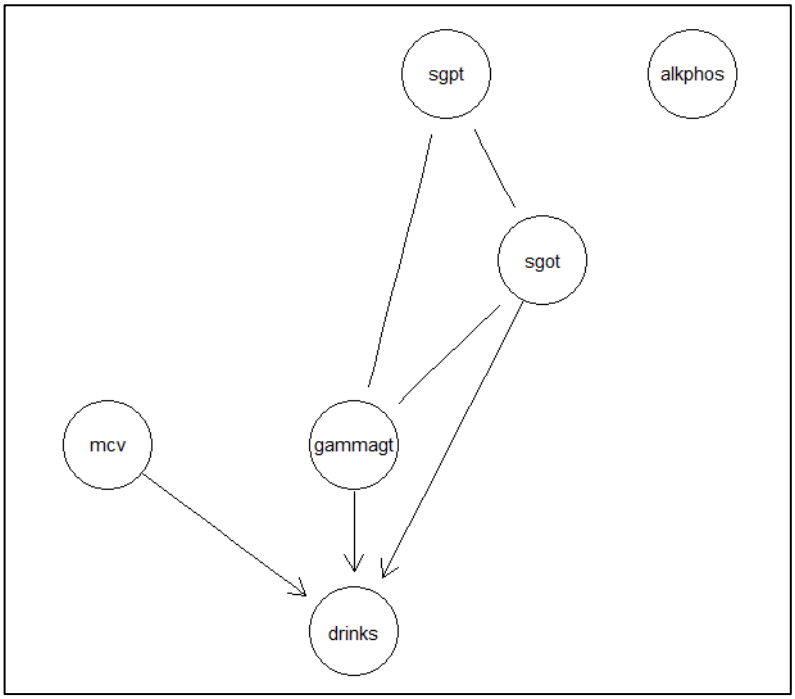

rys. 2-5 Sieć zbudowana algorytmem iamb dla danych ciągłych

## 2.3. Dane dyskretyzowane

Sieci otrzymane po dyskretyzowaniu danych nie były zadowalające, przez co przebudowane zostały na wzór swoich odpowiedników dla danych ciągłych. W początkowej dyskretyzacji zmienne podzieliłem na odpowiednio 3, 3, 4, 5, 6, 7 przedziałów.

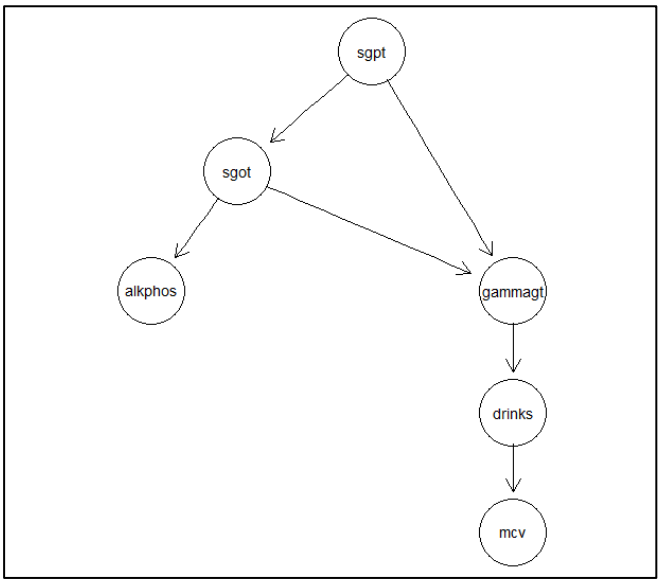

rys. 2-6 Sieć zbudowana algorytmem hc dla danych dyskretnych

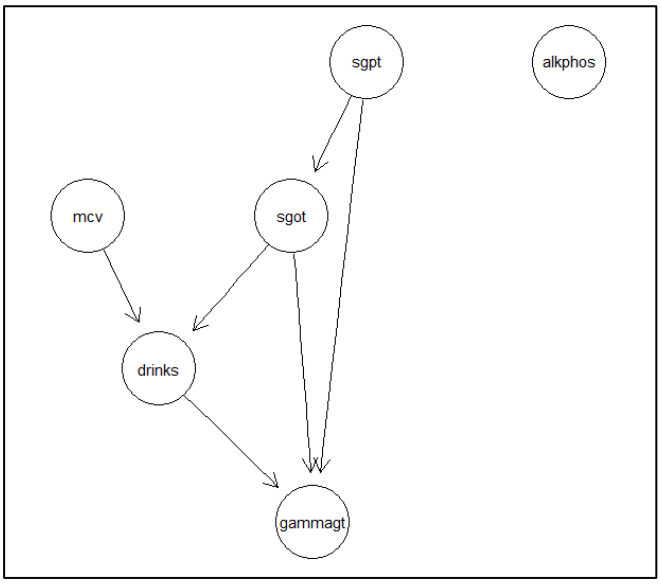

rys. 2-7 Sieć zbudowana algorytmem pc.stable dla danych dyskretnych

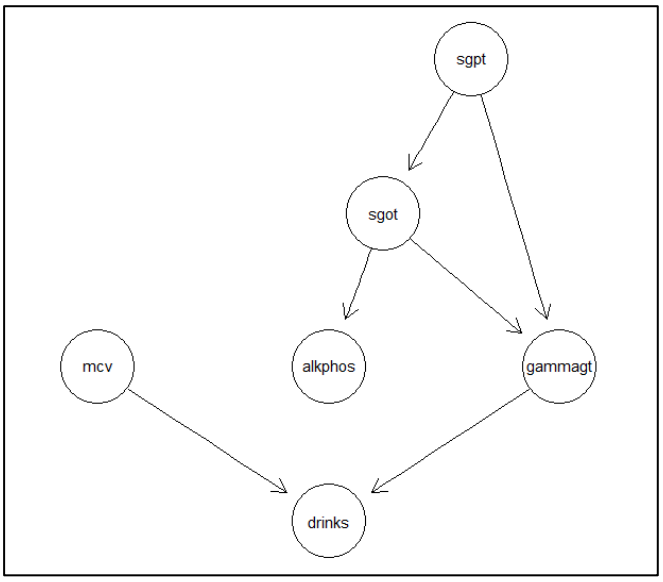

rys. 2-8 Sieć zbudowana algorytmem gs dla danych dyskretnych

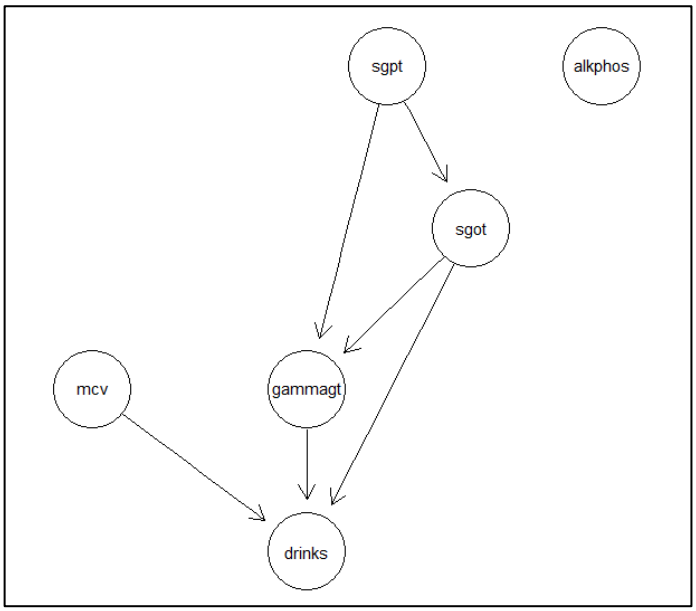

rys. 2-9 Sieć zbudowana algorytmem iamb dla danych dyskretnych

## 2.4. Score

Najlepszy wynik został otrzymany dla sieci zbudowanej algorytmem hc dla danych dyskretnych. Jest on najbliżej zera i wynosi -2071.689.

| Nazwa algorytmu budującego sieć | Dane dyskretyzowane? | Score |
|---|---|---|
| hc | nie | -7766.483 |
| | tak | -2071.689 |
| pc.stable | nie | graf częściowo skierowany |
| | tak | -3898.508 |
| gs | nie | graf częściowo skierowany |
| | tak | -2249.955 |
| iamb | nie | graf częściowo skierowany |
| | tak | -3450.4 |

tab. 2 Score dla zbudowanych sieci

## 2.5. Testy dyskretyzacji

W celu osiągnięcia najlepszej oceny modelu przeprowadziłem testy na ile przedziałów należy podzielić każdą kolumnę danych. Do testów użyłem modelu sieci zbudowanej przy pomocy algorytmu hc.

Algorytm sumował ile wartości znajduje się w danym przedziale i liczył odległości między wartościami. Celem było znalezienie takiej liczby podziałów danych w kolumnie, by odległości były jak najmniejsze. Taki zabieg sprawiał, że dane były rozłożone równomiernie.

```
> test(max_dist = 1000, a_1 = T)
  distance break_no
1      289        3
> test(max_dist = 1000, a_2 = T)
  distance break_no
1      187        3
> test(max_dist = 1000, a_3 = T)
  distance break_no
1      325        3
> test(max_dist = 1000, a_4 = T)
  distance break_no
1      311        3
> test(max_dist = 1000, a_5 = T)
  distance break_no
1      325        3
> test(max_dist = 1000, a_6 = T)
  distance break_no
1      327        3
```

rys. 2-10 Wynik funkcji sprawdzającej optymalną liczbę przedziałów

Najlepszym sposobem okazało się podzielenie wszystkich kolumn na 3 przedziały. **Score** nowej sieci wynosił **-1154.221**, co jest znaczącym polepszeniem w porównaniu do poprzedniego -2071.689. Algorytm musiał przeprowadzić 30 iteracji testów aby nauczyć się tej sieci

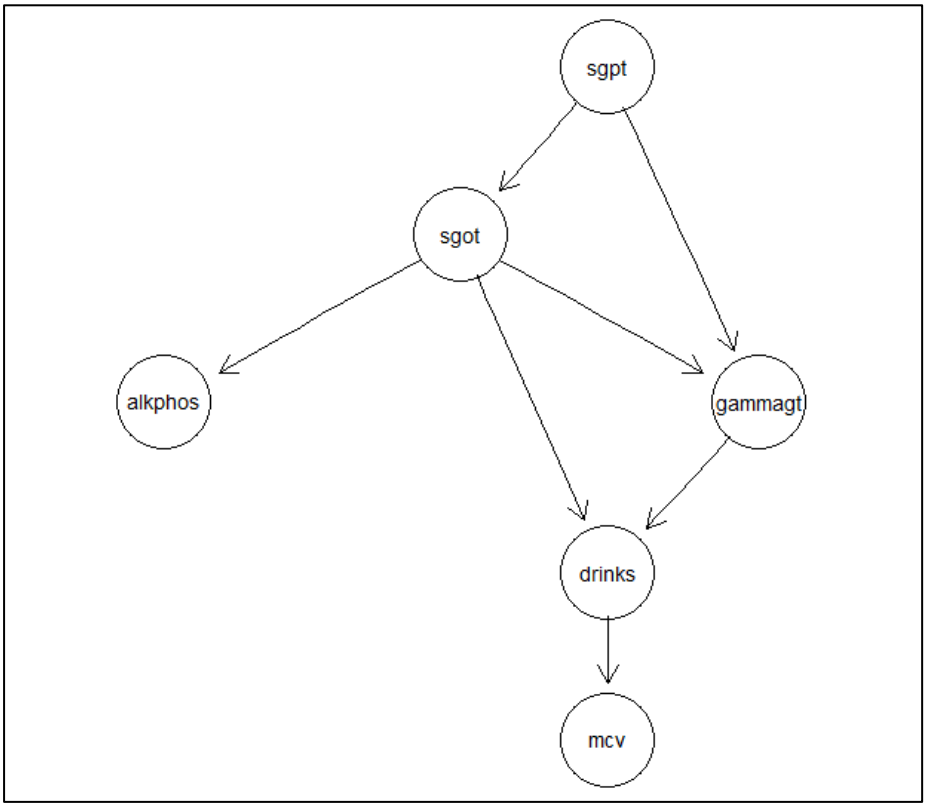


rys. 2-11 Ulepszona sieć zbudowana algorytmem hc

# 3. Wnioskowanie

## 3.1. Prawdopodobieństwa warunkowe

### 3.1.1. Obliczone ręczenie

Prawdopodobieństwo wystąpienia sgot znajdującego się w przedziale [5, 30.6667] pod warunkiem sgpt będącego w przedziale [4,54.3333] wynosi 90%.

$$P(sgot = [5, 30.6667] \mid sgpt = [4, 54.3333])$$
$$= \frac{P(sgot = [5, 30.6667] \cap sgpt = [4, 54.3333])}{P(sgpt = [4, 54.3333])} =$$
$$= \frac{\frac{283}{345}}{\frac{315}{345}} \approx \frac{0.82}{0.91} \approx 0.90$$

Prawdopodobieństwo wystąpienia sgot znajdującego się w przedziale [30.6667,56.3333] pod warunkiem sgpt będącego w przedziale [104.6667,155] wynosi 25%.

$$P(sgot = [30.6667, 56.3333] \mid sgpt = [104.6667, 155]) =$$
$$= \frac{P(sgot = [30.6667, 56.3333] \cap sgpt = [104.6667, 155])}{P(sgpt = [104.6667, 155])} =$$
$$= \frac{\frac{1}{345}}{\frac{4}{345}} \approx \frac{0.003}{0.012} \approx 0.25$$

Prawdopodobieństwo wystąpienia alkphos znajdującego się w przedziale [61.3333,99.6667] pod warunkiem sgot będącego w przedziale [5,30.6667] i sgpt będącego w przedziale [104.6667,155] wynosi 56%.

$$P(alkphos = [61.3333, 99.6667] \mid sgot = [5, 30.6667], sgpt = [4, 54.3333])$$
$$= \frac{P(alkphos = [61.3333, 99.6667] \cap sgot = [5, 30.6667] \cap sgpt = [4, 54.3333])}{P(sgot = [5, 30.6667] \cap sgpt = [4, 54.3333])} =$$
$$= \frac{\frac{158}{345}}{\frac{283}{345}} \approx \frac{0.46}{0.82} \approx 0.56$$

### 3.1.2. Obliczone w R

Jak widać funkcja w języku R zwróciła takie same wyniki jak przy obliczaniu prawdopodobieństw ręcznie.

```
 sgot pod warunkiem sgpt = [4,54.3333]
sgot
      [5,30.6667] (30.6667,56.3333]      (56.3333,82]
      0.898412698       0.095238095       0.006349206

 sgot pod warunkiem sgpt = (54.3333,104.667]
sgot
      [5,30.6667] (30.6667,56.3333]      (56.3333,82]
       0.11538462        0.84615385        0.03846154

 sgot pod warunkiem sgpt = (104.667,155]
sgot
      [5,30.6667] (30.6667,56.3333]      (56.3333,82]
             0.00              0.25              0.75
```

rys. 3-1 Prawdopodobieństwo sgot pod warunkiem sgpt

```
 alkphos pod warunkiem sgot = [4,54.3333]
alkphos
     [23,61.3333] (61.3333,99.6667]     (99.6667,138]
       0.36363636        0.56293706        0.07342657

 alkphos pod warunkiem sgot = (54.3333,104.667]
alkphos
     [23,61.3333] (61.3333,99.6667]     (99.6667,138]
        0.2641509         0.6603774         0.0754717

 alkphos pod warunkiem sgot = (104.667,155]
alkphos
     [23,61.3333] (61.3333,99.6667]     (99.6667,138]
        0.1666667         0.8333333         0.0000000
```

rys. 3-2 Prawdopodobieństwo alkphos pod warunkiem sgot

W przypadku prawdopodobieństwa wystąpienia gammagt pod warunkami sgpt i sgot wyniki prezentują się następująco:

```
 gammagt pod warunkiem sgpt i sgot = [4,54.3333] [5,30.6667]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
      0.971731449       0.021201413       0.007067138

 gammagt pod warunkiem sgpt i sgot = [4,54.3333] (30.6667,56.3333]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
       0.80000000        0.16666667        0.03333333

 gammagt pod warunkiem sgpt i sgot = [4,54.3333] (56.3333,82]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
              0.5               0.0               0.5

 gammagt pod warunkiem sgpt i sgot = (54.3333,104.667] [5,30.6667]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
                1                 0                 0

 gammagt pod warunkiem sgpt i sgot = (54.3333,104.667] (30.6667,56.3333]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
        0.7272727         0.1363636         0.1363636

 gammagt pod warunkiem sgpt i sgot = (54.3333,104.667] (56.3333,82]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
                0                 1                 0

 gammagt pod warunkiem sgpt i sgot = (104.667,155] [5,30.6667]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
              NaN               NaN               NaN

 gammagt pod warunkiem sgpt i sgot = (104.667,155] (30.6667,56.3333]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
                0                 1                 0

 gammagt pod warunkiem sgpt i sgot = (104.667,155] (56.3333,82]
gammagt
      [5,102.333] (102.333,199.667]     (199.667,297]
        0.3333333         0.6666667         0.0000000
```

rys. 3-3 Prawdopodobieństwo gammagt pod warunkiem sgpt i sgot

## 3.2. Rozkłady warunkowe

Prawdopodobieństwa można również zobrazować przy pomocy wykresów słupkowych.

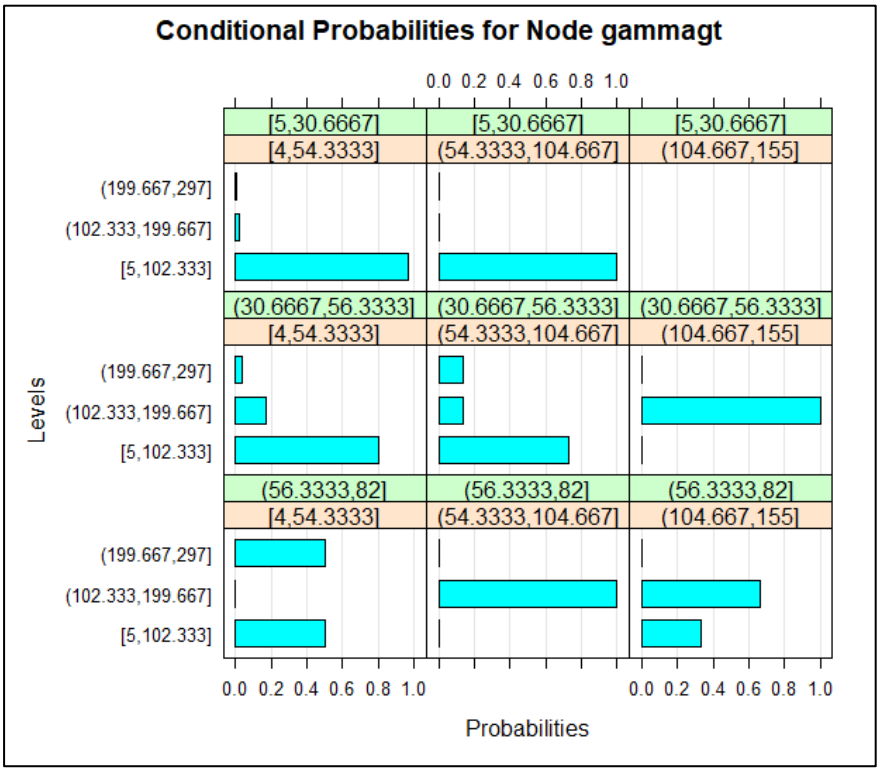


rys. 3-4 Rozkłady warunkowe dla węzła gammagt

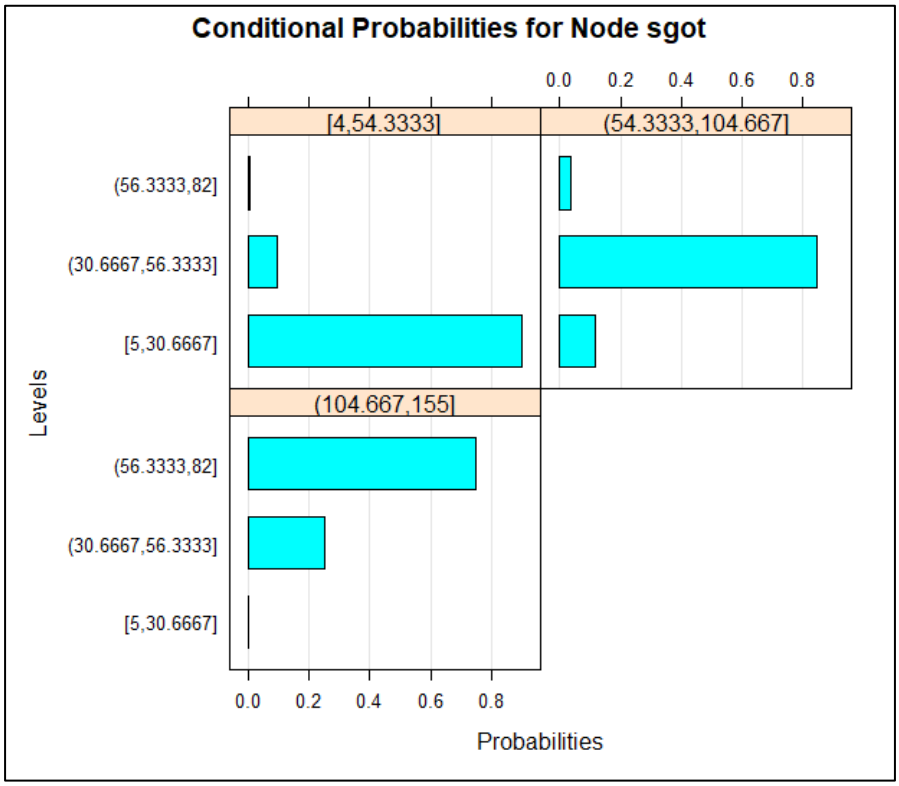


rys. 3-5 Rozkłady warunkowe dla węzła sgot

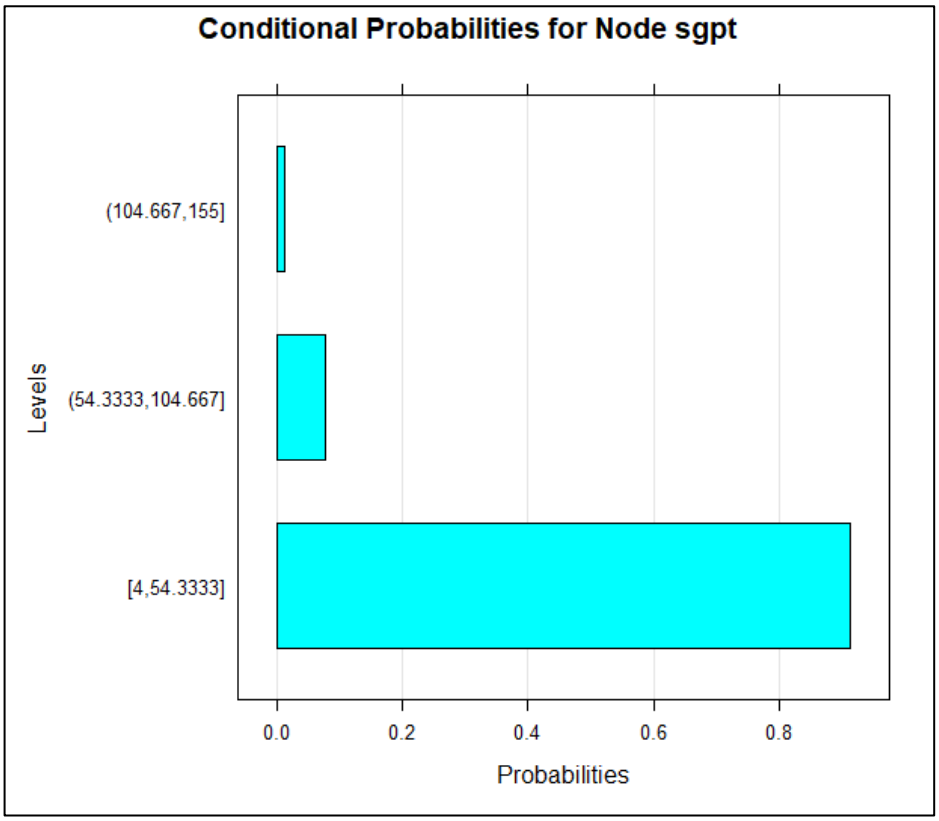


rys. 3-6 Rozkłady warunkowe dla węzła sgpt

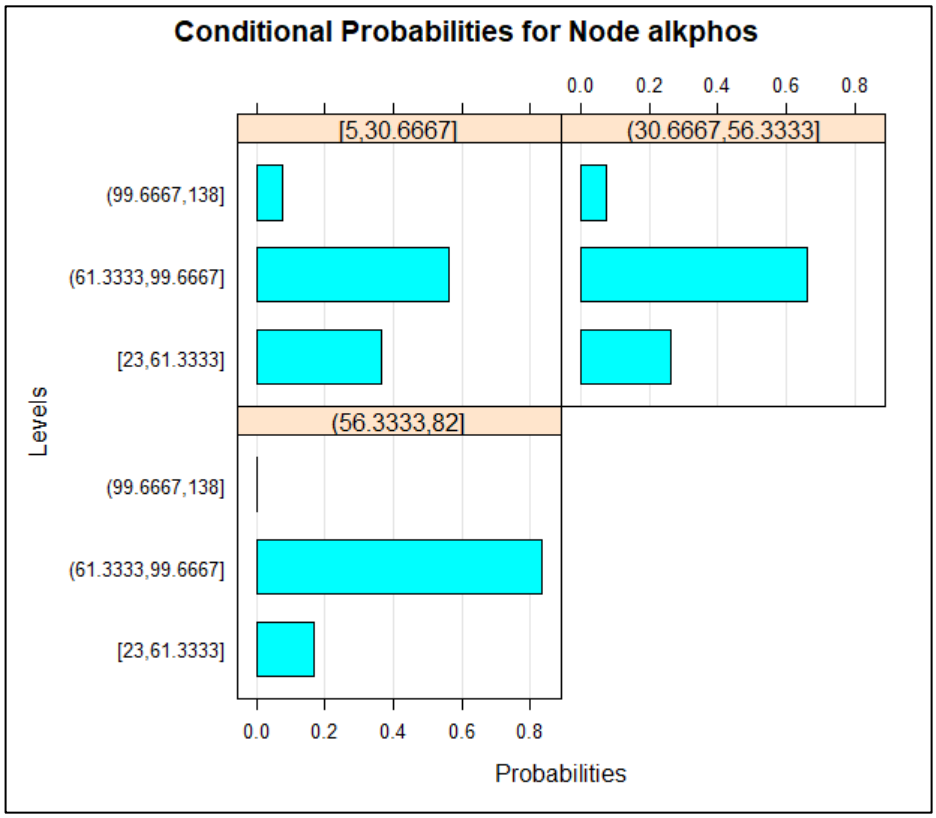


rys. 3-7 Rozkłady warunkowe dla węzła alkphos

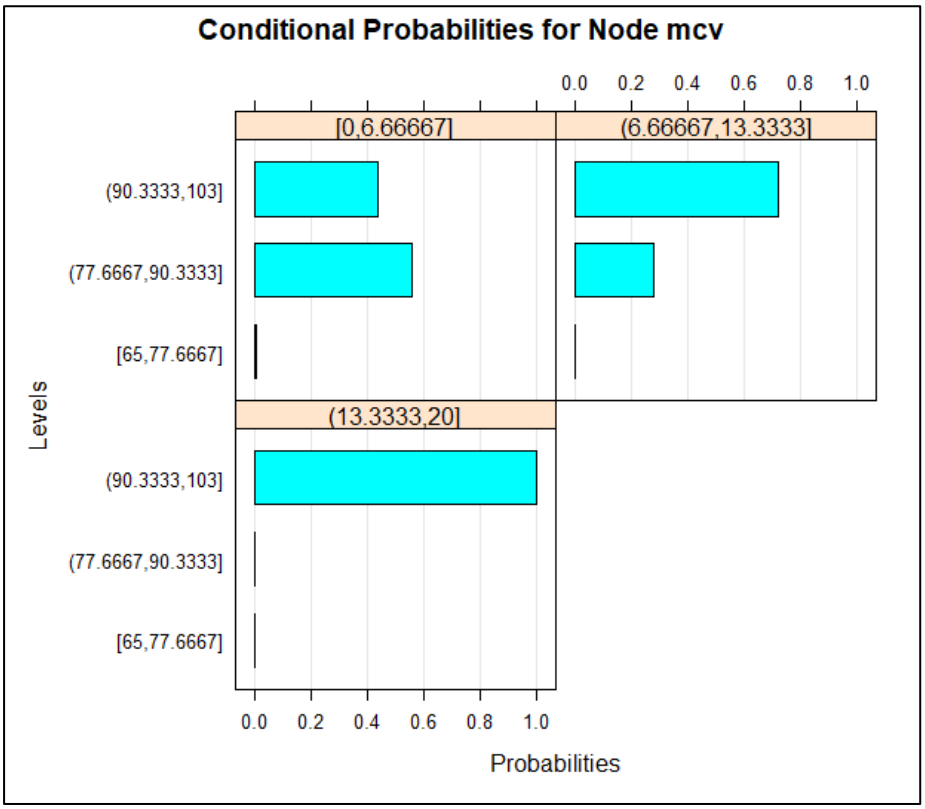


rys. 3-8 Rozkłady warunkowe dla węzła mcv

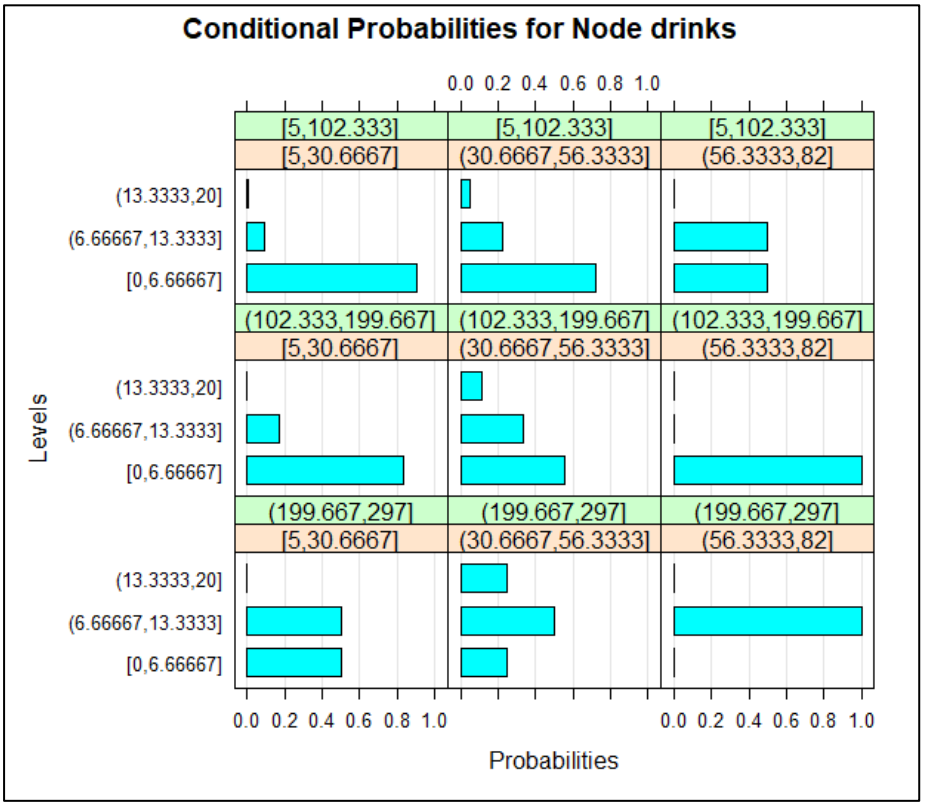


rys. 3-9 Rozkłady warunkowe dla węzła drinks

# 4. Podsumowanie

W przypadku wszystkich sprawdzanych modelów zmienna sgpt znajdowała się na samej górze i od niej zależały inne węzły. Zmienną najbardziej zależną od niej było sgot i gammagt. W większości przypadków alkphos znajdowało się poza modelem sieci lub uzależnione było od sgot. W tylko jednym przypadku gammagt wynikało z drinks – w każdym innym było odwrotnie. Podobna sytuacja dotyczy się zmiennych mcv i drinks. W co 3 modelu mcv było uzależnione od drinks – w reszcie odwrotnie.

# 5. Spis ilustracji



# 6. Spis tabel



# 7. Kod źródłowy

https://github.com/gabriellichacz/bayesian_network_liver